NEPAgent: Executive Summary

CJ 4DPLEX AI 개발 사전과제 · Track 1 Motion Prediction Agent

1. 문제 정의

Track 1(Motion Prediction)을 **다음 사건 예측(Next-Event Prediction, NEP)**으로 구체화했습니다. NEPAgent는 영상의 앞부분(관찰 구간)만 보고, 바로 다음에 일어날 사건을 한 문장으로 예측하고 그 근거를 함께 제시합니다.

구분	내용
해결하는 문제	관찰 영상으로부터 후속 사건을 예측하는 Video AI Agent 개발
기술적 필요성	시간에 따른 상태 변화와 행동 간 인과관계를 추론하는 능력의 검증
Agent가 필요한 이유	제한된 관찰 정보에서 필요한 증거를 선택적으로 다시 확인하고 추론하기 위함

NEP를 고른 것은 영상 모델의 시간적·인과적 이해 능력을 검증하기 위해서이고, Agent 구조를 고른 것은 예측에 부족한 시각적 증거를 능동적으로 보완하기 위해서입니다. 입력은 영상의 관찰 구간이며(이후 영상, 정답, 보기는 사용하지 않음), 출력은 다음 사건 예측 문장과 근거(마지막 상태, 근거 프레임 번호, 인과 전이)입니다.

2. 접근 방식

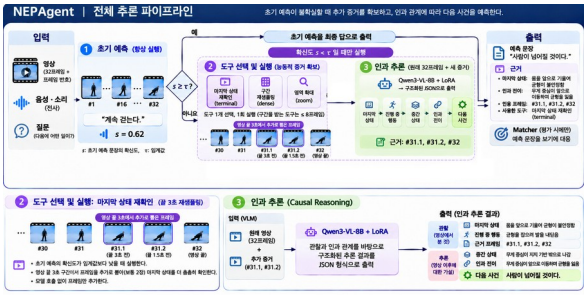


그림 1. 추론 파이프라인. 초기 예측의 확신도가 높으면(≥ 0.75) 바로 끝내고(test 문항의 54%), 낮으면 도구로 영상을 다시 본 뒤 인과 추론으로 예측을 다시 씁니다. 모든 단계가 Qwen3-VL-8B에 직접 학습한 LoRA를 붙인 단일 모델로 동작하며 외부 API는 쓰지 않습니다.

그림 2. 도구 3종. 마지막 상태 재확인(영상 끝 3초에서 프레임 2장 추가), 구간 재샘플링(고른 구간의 프레임 사이를 촘촘히 추가), 영역 확대(모델이 지목한 물체를 찾아 확대). 어떤 도구를 쓸지는 모델이 고릅니다.

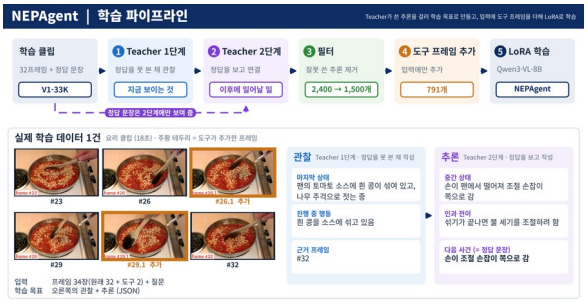


그림 3. 학습 파이프라인. V1-33K 학습 클립 1,500건에 2단계 Teacher를 적용했습니다. 1단계는 정답 없이 관찰만, 2단계는 정답을 보고 관찰과 정답을 잇는 추론만 씁니다. 추론 때의 입력과 맞추기 위해 절반가량의 입력에 도구가 추가하는 프레임을 넣었습니다. LoRA 학습은 A100 1장으로 약 6.9 시간입니다.

3. 주요 결과

학습 없는 Qwen3-VL-8B(순수 Qwen)와 비교했습니다. 보기 없이 문장을 예측한 뒤 보기에 대응시켜 채점했습니다.

범위	문항	순수 Qwen	NEPAgent	차이
test 전체	328	44.8	**50.6**	**+5.8**
FutureBench	200	50.0	57.5	+7.5
FutureOmni Speech	128	36.7	39.8	+3.1

test 328문항에서 정확도가 5.8pp 높습니다(FutureBench +7.5pp, FutureOmni Speech +3.1pp).

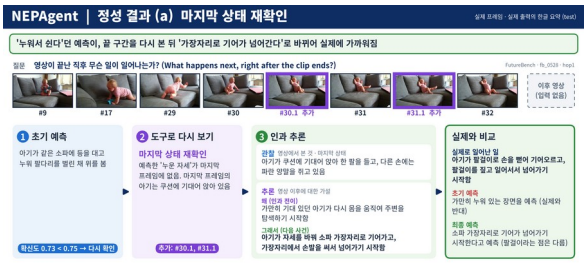


그림 4. 사례(마지막 상태 재확인). 초기 예측은 "아기가 누워서 쉰다"였습니다. 영상 끝 구간을 다시 보고 아기가 앉아 있는 것을 확인한 뒤 "소파 가장자리로 기어가 넘어간다"로 바뀌어, 실제 다음 장면(팔걸이를 기어오름)에 가까워졌습니다.

4. 리스크와 향후 개선 방향

리스크	향후 개선 방향
음악·효과음 같은 비언어 소리를 입력으로 쓰지 않음	오디오를 직접 입력받는 모델, 효과음 문항으로 평가 확대
도구 선택을 학습하지 않고, 도구를 1회만 실행	도구를 상황에 맞게 고르도록 학습
확신도 게이트가 오답을 잘 걸러 내지 못함	여러 번 예측해 일치하는 정도를 확신도로 사용
학습 데이터가 1,500건, 한 출처	데이터 규모와 출처 확대

상세 내용은 `docs/Technical_Report.md`, 구조는 `docs/System_Architecture.md`, 사용 내역은 `docs/Usage_and_Implementation.md`에 있습니다.