NEPAgent: 관찰 영상 기반 다음 사건 예측 Agent

CJ 4DPLEX AI 개발 사전과제 · Track 1 Motion Prediction Agent · Technical Report

요약

구분	내용
목표	Track 1(Motion Prediction)을 **다음 사건 예측(Next-Event Prediction, NEP)**으로 구체화. 영상의 관찰 구간만 보고, 직후에 일어날 사건을 한 문장으로 예측하고 근거를 함께 제시하는 Agent
접근	Qwen3-VL-8B [1] + LoRA 단일 모델. 초기 예측을 낸 뒤, 확신도가 낮은 문항만 도구로 영상을 다시 보고 인과 추론으로 예측을 다시 씁니다
결과	test 328문항에서 학습 없는 Qwen3-VL-8B 대비 **44.8% → 50.6% (+5.8pp)**
한계	비언어 소리(음악·효과음)를 입력으로 쓰지 않고, 도구 선택을 학습하지 않았습니다(7절)

---

1. 문제 정의

1.1 배경

Track 1은 영상에서 시간에 따라 변하는 정보를 분석해 이후의 변화를 예측하는 과제입니다. 본 과제에서는 이를 **다음 사건 예측 (Next-Event Prediction, NEP [3])**으로 구체화했습니다.

구분	내용
해결하는 문제	관찰 영상으로부터 후속 사건을 예측하는 Video AI Agent 개발
기술적 필요성	시간에 따른 상태 변화와 행동 간 인과관계를 추론하는 능력의 검증
Agent가 필요한 이유	제한된 관찰 정보에서 필요한 증거를 선택적으로 다시 확인하고 추론하기 위함

- **NEP를 고른 이유(미래 예측의 필요성)**: 다음 사건을 맞히려면 사건의 순서, 마지막 상태, 진행 중인 행동, 그 사이의 인과 흐름을 함께 이해해야 합니다. 즉 영상 모델의 시간적·인과적 이해 능력을 직접 검증할 수 있는 문제입니다. 공개된 평가 벤치마크와 학습 데이터가 있어 기간 안에 학습과 정량 검증이 모두 가능합니다.

- **Agent 구조를 고른 이유(Agent의 필요성)**: 균등 샘플링한 프레임만으로는 마지막 순간이나 작은 대상처럼 예측에 필요한 시각적 증거가 부족할 때가 있습니다. Agent는 예측이 불확실할 때 필요한 구간을 스스로 골라 다시 확인하고, 그 증거로 추론을 다시 합니다.

1.2 과제 정의

항목	정의
입력	영상의 관찰 구간(0초 ~ 분할 시점). 벤치마크에서는 주석이 지정한 시점까지 자른 클립
예측 대상	관찰 구간 직후의 다음 사건 1개 (자연어 한 문장)
출력	예측 문장, 근거(마지막 상태, 근거 프레임 번호, 인과 전이), 사용한 도구와 구간
사용 금지 정보	분할 시점 이후 영상, 정답 문장, 보기. 보기는 예측이 끝난 뒤 채점에만 씁니다

1.3 성공 기준

기준	결과
같은 기반 모델(학습 없는 Qwen3-VL-8B)보다 test 정확도가 높음	달성 (+5.8pp, 5.1절)
예측 단계에 미래 정보가 들어가지 않음	달성 (`tests/test_no_leakage.py`)
추가 단계를 거친 예측은 근거를 함께 출력함	달성 (3.4절)
추가 단계는 불확실한 문항에만 적용함	달성 (54% 문항은 초기 예측으로 종료)

---

2. 데이터 구성

2.1 평가 데이터

벤치마크	형식	사용 범위
FutureBench [3]	4지선다. 관찰 이후 몇 단계 뒤 사건(hop 1/2/3/5)	test 200문항
FutureOmni [2]	5지선다. 영상·오디오 맥락의 다음 사건	test 중 말소리(Speech) 128문항

- **test = 328문항**(FutureBench 200 + FutureOmni Speech 128)입니다. 분할은 영상 단위이며 학습 데이터와 겹치는 영상은 없습니다.
- NEPAgent는 오디오를 음성 전사로만 받으므로, FutureOmni는 입력 설계가 다루는 말소리 문항만 평가했습니다. 이 범위는 오디오 종류별 결과를 확인한 뒤 정했습니다.
- 두 벤치마크의 표준 평가는 보기를 함께 주는 객관식입니다. **NEPAgent는 보기 없이 문장을 생성하고, 보기는 채점에만 씁니다**(5절).

2.2 학습 데이터

V1-33K [3] 학습 클립에 Qwen3-VL-8B를 Teacher로 적용해 추론 학습 데이터 1,500건을 만들었습니다.

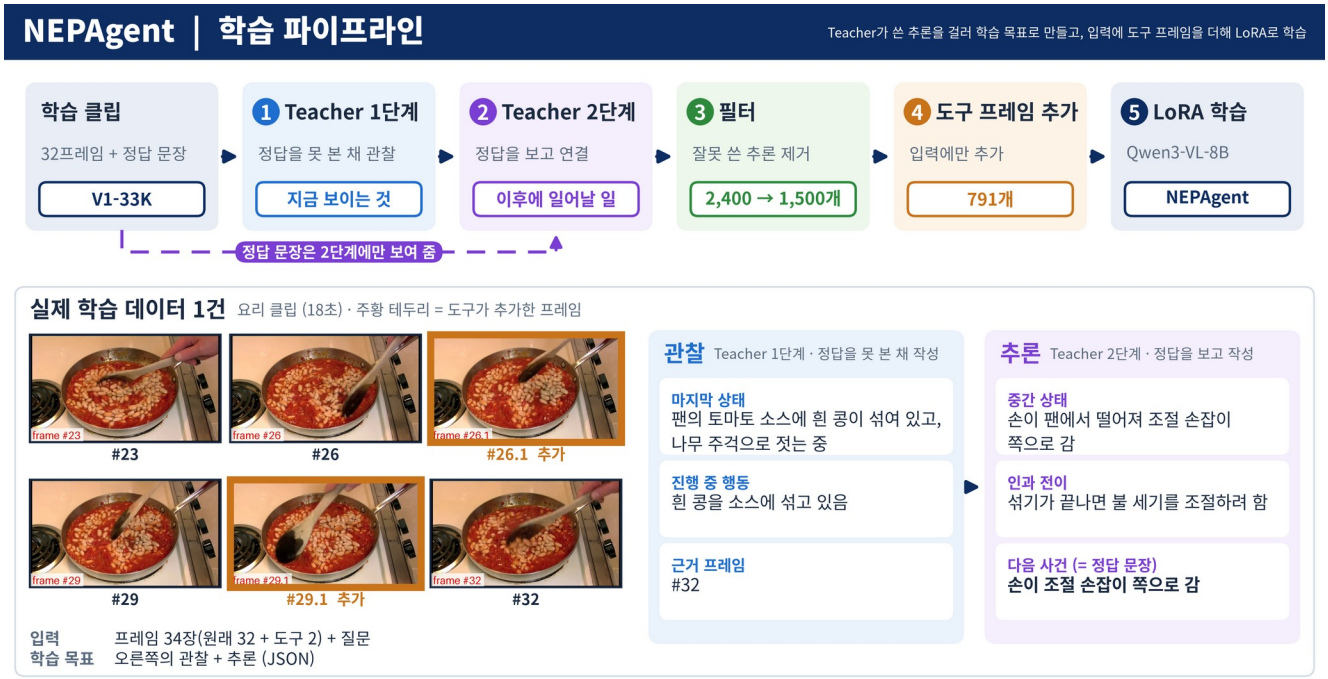


그림 1. 학습 파이프라인(위)과 실제 학습 데이터 1건(아래). 주황 테두리 `#26.1`, `#29.1`은 도구가 추가한 프레임입니다.

단계	내용
① Teacher 1단계 (정답 미제공)	프레임만 보고 마지막 상태, 진행 중 행동, 근거 프레임을 작성
② Teacher 2단계 (정답 제공)	1단계 관찰을 고정하고, 정답 문장까지 이어지는 중간 상태와 인과 전이만 작성
③ 필터	JSON 오류, 인과 전이 누락, 관찰 구간을 되짚는 표현, 정답을 그대로 베낀 중간 상태를 규칙으로 제거
④ 도구 프레임 추가	1,500건 중 791건의 입력에 추론 때와 같은 코드로 도구 프레임을 더함(마지막 상태 재확인 640, 구간

단계	내용
	재샘플링 151). 학습 목표는 그대로 둠

- **정답을 2단계에서만 보여 준 이유**: 처음부터 정답을 주면 관찰 서술에 정답이 섞일 수 있습니다.
- **1,500건의 구성**: 1차 표본 1,500개 중 필터 통과 997개 + 같은 풀에서 추가로 뽑은 후보 900개 중 통과분 503개. 필터 기준은 결과를 보기 전에 정했고, 통과분이 적어도 완화하지 않았습니다.
- **도구 프레임을 학습 입력에 넣은 이유**: 추론 때 불확실한 문항의 입력은 원래 32프레임에 도구 프레임이 더해진 형태입니다. 학습 입력을 이 형태와 맞췄습니다.
- **영상 출처**: YouTube 817, ActivityNet 329, YouCook2 195, NExT-QA 159. 평가 영상과 Charades·Ego4D 출처는 제외했습니다.

데이터의 출처와 라이선스는 `docs/Usage_and_Implementation.md`에 정리했습니다.

---

3. Agent 설계

3.1 전체 구조

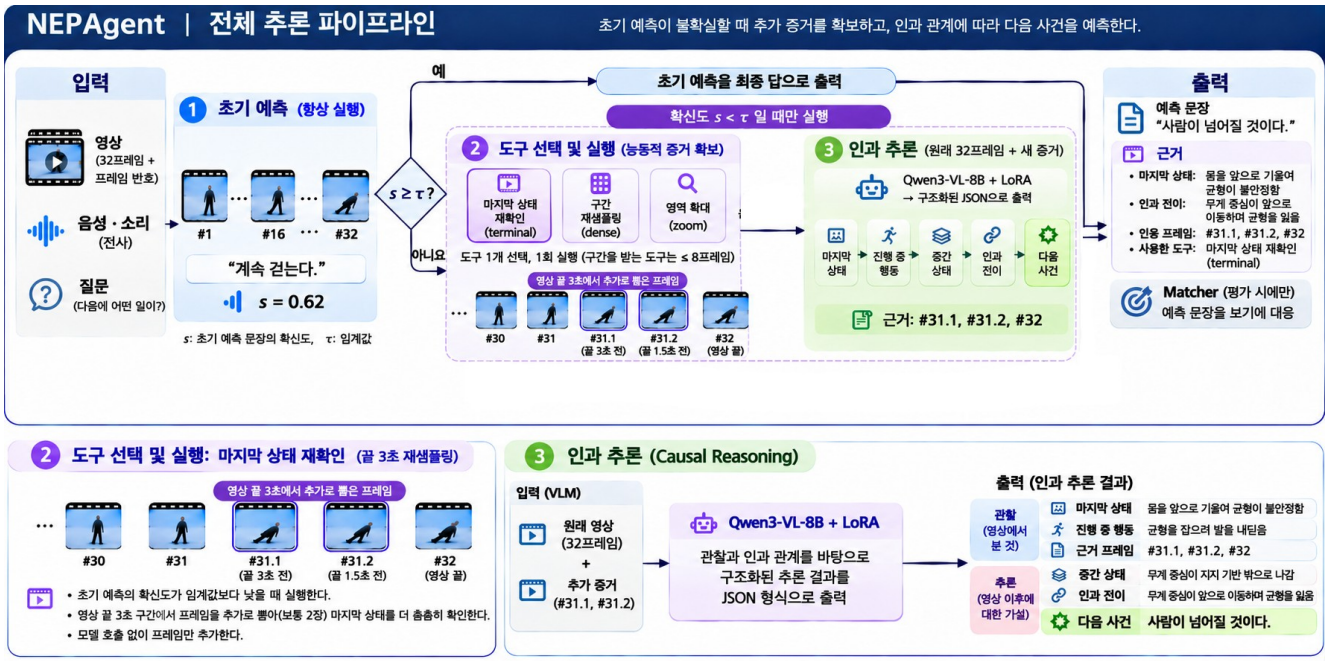


그림 2. 추론 파이프라인.

단계	하는 일	실행 조건
1. 초기 예측	프레임 번호를 표시한 32프레임(ViKey [6] 방식)과 Whisper [7] 음성 전사를 보고 다음 사건을	항상

단계	하는 일	실행 조건
	한 문장으로 예측. 생성 확신도를 함께 기록	
2. 확신도 게이트	확신도 ⩾ 0.75이면 초기 예측으로 종료	항상
3. 도구 선택	도구 1개, 구간, 확인할 대상(cue)을 모델이 고름	확신도 < 0.75
4. 도구 실행	프레임 추가 또는 영역 확대 (모델 호출 없음)	확신도 < 0.75
5. 인과 추론	원래 프레임 + 추가 프레임을 보고 마지막 상태 → 인과 전이 → 다음 사건을 JSON으로 작성	확신도 < 0.75
6. Matcher	예측 문장을 보기에 대응 (텍스트만 사용)	보기가 있을 때 (평가용)

- 모든 단계가 같은 모델(Qwen3-VL-8B + NEPAgent LoRA)을 쓰며 temperature는 0입니다.
- 5단계가 답을 내지 못하면(JSON 형식 실패 등) 도구 없이 원래 프레임만으로 인과 추론을 한 번 더 하고, 그것도 실패하면 초기 예측을 씁니다.

3.2 설계 결정과 근거

결정	이유
초기 예측 우선 + 확신도 게이트	모든 문항에 추가 단계를 적용하면 처리 시간이 늘고, 맞힌 답을 틀리게 바꾸기도 합니다. test에서 게이트를 둔 구성(50.6)이 추가 단계를 모든 문항에 적용한 구성(50.0)보다 낮지 않았습니다
도구로 다시 보기	32프레임 균등 샘플링은 긴 영상에서 프레임 간격이 수 초 이상 벌어져 마지막 순간이나 짧은 동작을 놓칩니다
인과 추론을 JSON으로 학습	답만 학습하면 근거가 나오지 않습니다. 예측을 사람이 검증하려면 마지막 상태와 근거 프레임이 필요합니다
보기 없이 예측	실제 사용 환경에는 보기가 없습니다

Teacher로 추론 과정을 만들어 학습하는 방식은 Video-CoE [4], 관찰 구간을 다시 보는 도구와 인과 전이 추론은 VepAgent [5]를 참고했습니다. 가져온 것과 다르게 한 것은 `docs/Usage_and_Implementation.md` 4절에 정리했습니다.

3.3 도구

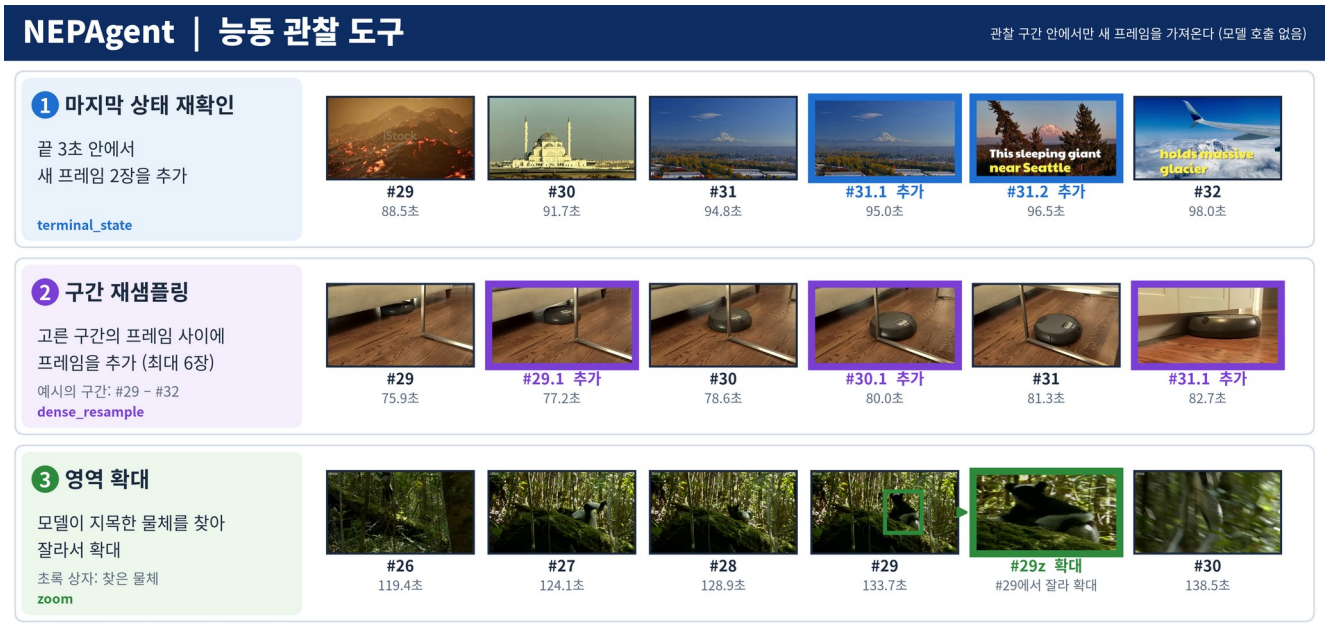


그림 3. 도구 3종의 실제 실행 예시.

도구	기능
마지막 상태 재확인	영상 끝 3초 구간에서 새 시점의 프레임 2장을 추가 (예: `#31.1`, `#31.2`)
구간 재샘플링	모델이 고른 구간의 프레임 사이에 최대 6장을 추가
영역 확대	모델이 쓴 cue의 물체를 Grounding DINO [8]로 찾아 잘라 확대

- 도구 실행은 규칙 기반이고, 어떤 도구를 고를지는 프롬프트로만 정합니다(학습하지 않음).
- test에서 확신도가 낮았던 150문항에 모델이 고른 도구는 마지막 상태 재확인 113회, 구간 재샘플링 37회, 영역 확대 0회입니다.

3.4 출력 형식

인과 추론은 관찰한 것과 추론한 것을 구분해 출력합니다.

```
{"observed": {"terminal_state": "...", "ongoing_action": "...", "supporting_evidence": ["#31.1", "#32"]},
 "inferred": {"intermediate_states": ["..."], "causal_transition": "...", "predicted_event": "..."}}
```

필드	의미
`observed`	관찰 구간에서 본 것: 마지막 상태, 진행 중 행동, 근거 프레임 번호

필드	의미
`inferred`	관찰 이후에 대한 가설: 중간 상태, 인과 전이, 예측 사건

---

4. 구현 방법

4.1 모델 학습

항목	값
기반 모델	Qwen3-VL-8B-Instruct, vision tower 고정
방식	LoRA (r 64, α 128), lr 1e-5, 3 epoch, 유효 배치 16
데이터	2.2절의 1,500건
자원	학습: A100 80GB 1장, 약 6.9시간. 추론: GPU 1장(A100 80GB 또는 RTX A6000 48GB)
프레임워크	LLaMA-Factory, PEFT

4.2 코드 구성

영역	경로
프레임 샘플링·번호 표시, 도구 실행	`src/agent/`
초기 예측, 게이트, 도구 선택, Matcher와 프롬프트	`src/stages/`
인과 추론, 전체 흐름	`src/nep_agent/`
학습 데이터 생성, 학습 설정	`src/train/`
실행 설정	`configs/nep_agent.yaml`(최종), `configs/plain_qwen.yaml`(비교 대상)
실행·평가 스크립트	`scripts/run_agent.py`, `scripts/run_benchmark.py`, `scripts/main_table.py`
테스트	`tests/` (미래 정보 누출 검사 포함)

실행 방법은 `README.md`, 사용한 모델·데이터·오픈소스는 `docs/Usage_and_Implementation.md`에 있습니다.

---

5. 평가 및 검증 결과

평가 방법

항목	내용
비교 대상	순수 Qwen: 학습 없는 Qwen3-VL-8B, 32프레임, 프레임 번호·오디오 없음
지표	정확도. Matcher가 예측 문장에 대응시킨 보기가 정답 보기와 같은 비율
지표를 고른 이유	실제 사용 환경에는 보기가 없으므로 보기 없이 문장을 예측하게 하고, 사람이 만든 벤치마크 정답을 기준으로 맞았는지를 판정하기 위함입니다
정답 기준	벤치마크 주석의 정답 보기(실제 이후 영상에서 일어난 사건)

순수 Qwen과 NEPAgent는 가중치(LoRA), 입력(프레임 번호, 음성 전사), 추가 단계가 모두 다릅니다. 따라서 아래 차이는 이 요소들의 합산 효과입니다.

5.1 주요 결과

표 1. 순수 Qwen 대비 NEPAgent (test, 정확도 %)

범위	문항	순수 Qwen	NEPAgent	차이
전체	328	44.8	**50.6**	+5.8
FutureBench	200	50.0	57.5	+7.5
FutureOmni Speech	128	36.7	39.8	+3.1

- 전체 328문항에서 5.8pp 높습니다.
- FutureBench에서 +7.5pp, FutureOmni Speech에서 +3.1pp입니다.

5.2 도구별 비교

확신도가 낮은 150문항에 도구를 하나만 쓰도록 강제해 다시 실행했습니다. 나머지 178문항은 초기 예측을 그대로 씁니다.

표 2. 도구 구성별 정확도 (test, %)

구성	전체 328	FutureBench 200	FutureOmni Speech 128	확신도 낮은 150문항
순수 Qwen	44.8	50.0	36.7	41.3
마지막 상태 재확인만	50.0	56.5	39.8	48.0
구간 재샘플링만	50.0	57.0	39.1	48.0
영역 확대만	48.8	57.0	35.9	45.3
도구 3종 중 모델 선택 (NEPAgent)	**50.6**	**57.5**	**39.8**	**49.3**

- 모든 구성이 순수 Qwen보다 높습니다.
- 도구 간 차이는 작습니다(전체 기준 4문항 이내). 어느 도구가 어떤 유형에 유효하다고 구분할 근거는 없습니다.

5.3 테스트 케이스

초기 예측이 도구와 인과 추론을 거쳐 달라지는 과정을 도구별로 1건씩 보입니다. 세 사례 모두 초기 예측의 확신도가 0.75보다 낮아 추가 단계로 넘어간 문항입니다. 도구마다 그 도구가 필요한 조건의 영상을 골랐습니다: (a) 다음 행동이 마지막 순간의 자세에 달린 영상, (b) 끝 구간에서 장면이 빠르게 바뀌는 영상, (c) 작은 대상이 단서인 영상. 그림의 문장은 모델 출력을 한글로 요약한 것이고, 맨 위 한 줄은 사례의 요점입니다. 원문은 `results/qualitative/`의 사례 폴더에 있습니다.



그림 4. 사례 (a) 마지막 상태 재확인. 초기 예측 "누워서 쉰다" → 끝 구간을 다시 보고 아기가 앉아 있음을 확인 → "가장자리로 기어가 넘어간다". 실제 다음 장면(팔걸이를 기어오름)에 가까워졌으나 위치는 다릅니다. 벤치마크 질문 대신 고정 질문("영상이 끝난 직후 무슨 일이 일어나는가?")으로 실행한 기록입니다.



그림 5. 사례 (b) 구간 재샘플링. 초기 예측은 지금 보이는 장면(스쿠터를 미는 남자)을 그대로 서술해 오답 → 끝 구간에 5장을 추가해 본 뒤 "유니폼 여성이 전시장에서 설명함"을 예측해 정답. 구간 재샘플링만 쓰도록 한 실행의 기록입니다.



그림 6. 사례 (c) 영역 확대. 초기 예측 "차가 공중으로 날아감" → 마지막 두 프레임을 확대해 바주카포를 든 미니언을 확인 → "차가 진로를 벗어나 흔들림"(정답과 같은 내용). 영역 확대만 쓰도록 한 실행의 기록입니다.

- 사례는 이해하기 쉬운 것을 고른 동작 예시이며 정확도의 근거가 아닙니다.
- (b)만 초기 예측이 오답에서 정답으로 바뀐 문항입니다. (a)와 (c)는 초기 예측도 보기 채점으로는 정답에 대응했고, 예측 문장이 실제 사건에 가까워지는 과정을 보인 것입니다.
- (b)는 정답 장면의 인물이 관찰 영상 끝에 이미 등장합니다(7절 L7).

사례의 영상, 질문, 출력은 `results/qualitative/`에 있습니다.

6. 실패 분석

실패는 두 유형으로 나뉩니다.

유형	규모 (test)
A. 게이트를 통과한 오답	확신도가 높아 바로 끝난 178문항 중 86문항이 오답
B. 도구 사용 후 혼동	확신도 낮은 150문항 중, 초기 예측은 맞았으나 도구를 쓴 뒤의 추론이 틀린 답으로 바뀐 경우

6.1 유형 A: 게이트를 통과한 오답



그림 7. 실패 사례 A. 확신도 0.847로 추가 단계 없이 끝났으나 오답입니다.

항목	내용
사례	키보드 위에서 잠든 고양이를 손이 쓰다듬는 영상. 초기 예측 "고양이는 깨지 않고 계속 잠". 정답은 "고양이가 눈을 뜨고 깨어남"
원인	마지막 장면을 그대로 이어 쓴 "변화 없음" 예측은 생성 확률이 높아 확신도가 높게 나옵니다. 그래서 상태가 바뀌는 사건을 다시 검토할 기회가 없었습니다
한계	확신도로 초기 예측의 정답·오답을 가르는 성능(AUROC)이 0.55로 무작위(0.5)에 가깝습니다. 게이트는 추가 단계를 줄이는 데는 쓸모가 있지만 오답을 골라내는 신호로는 약합니다
개선	예측을 여러 번 샘플링해 서로 일치하는 정도를 확신도로 사용(self-consistency). 또는 초기 예측의 정답 여부를 예측하는

항목	내용
방향	분류기를 학습

6.2 유형 B: 도구 사용 후 혼동



그림 8. 실패 사례 B. 초기 예측은 정답이었으나 도구 사용 뒤 오답이 되었습니다.

항목	내용
사례	교실에서 막대를 든 경찰이 소란스러운 남자들과 대치하다가 한 남자에게 동요를 불러 보라고 하는 영상. 초기 예측은 정답("경찰이 막대로 남자를 때림")에 대응. 마지막 상태 재확인 뒤 "남자가 노래하고 경찰이 듣는다"로 바뀌어 오답
원인	끝 구간 프레임이 더해지자 추론이 끝 순간(노래를 시작하는 장면)에만 집중해, 앞에서 쌓인 대치 상황을 놓쳤습니다
한계	추가 프레임이 들어간 149문항 중 이를 근거로 인용한 추론은 8문항뿐입니다. 학습 목표가 원래 32프레임만 근거로 쓰고, 학습 입력의 도구도 모델의 실제 선택이 아니라 무작위로 배정했기 때문입니다
개선 방향	(1) 추론이 추가 프레임을 근거로 인용할 때만 그 답을 채택. (2) 모델이 실제로 고른 도구로 학습 입력을 만들고, 추가 프레임을 근거로 쓰는 학습 목표를 확보. (3) 도구 선택 자체를 학습(VepAgent [5])

실패 사례의 영상, 질문, 출력은 `results/failure_cases/`에 있습니다.

---

7. 한계 및 개선 방향

#	한계	내용	개선 방향
L1	소리 입력 범위	오디오는 Whisper 음성 전사로만 입력합니다. 음악·효과음은 입력에 들어가지 않으며, FutureOmni는 말소리 문항만 평가했습니다	**효과음 처리**: 오디오를 직접 입력받는 모델을 쓰거나, 소리 사건 탐지 결과를 프레임 번호에 맞춰 입력. 음악·효과음 문항으로 평가 확대
L2	학습 데이터 범위와 품질	학습 데이터 1,500건이 모두 FutureBench와 같은 출처(V1-33K)이고, FutureOmni 형식의 데이터는 없습니다. 8B Teacher가 쓴 마지막 상태가 정확한 비율은 감사 100건 중 51건입니다	**데이터셋 확장**: 클립 수와 출처(영화·감시·교육 등)를 넓히고, 더 큰 Teacher와 사람 검수로 품질 확보
L3	고정된 도구 사용	도구 1개를 1회만 실행하고, 도구 선택은 학습하지 않습니다. 학습 입력의 도구는 무작위로 배정했습니다. 확신도 게이트도 오답을 잘 걸러 내지 못합니다(6.1절)	**도구를 상황에 맞게 선택**: 모델이 실제로 고른 도구로 학습 입력을 만들고 도구 선택을 학습. 이후 강화학습(VepAgent [5])과 반복 호출로 확장
L4	고정된 프레임 샘플링	처음 입력은 영상 길이·내용과 무관하게 32프레임 균등 샘플링입니다	**프레임 선택도 상황에 맞게**: 장면 전환·움직임이 많은 구간은 촘촘히, 정적인 구간은 성기게 배분
L5	단일 물체 확대	영역 확대는 cue 하나로 물체 하나만 찾아 자릅니다. 여러 물체·인물의 상호작용은 한 대상만 확대됩니다	**다중 물체 확대**: cue를 여러 개 받아 물체별로 탐지·확대하고 물체 간 상대 위치를 함께 입력
L6	긴 영상	관찰 구간이 최대 865초이며, 32프레임이면 간격이 약 27초까지 벌어집니다	**영상 길이 대응**: 길이에 따라 프레임 수를 늘리거나, 구간별 요약 뒤 마지막 구간을 촘촘히 보는 계층형 입력
L7	평가 방식	Matcher가 질문과 보기를 보고, 평가 대상과 같은 모델로 실행됩니다. FutureBench는 질문에 이후 장면이 서술된 문항이 많고, 관찰 클립이 질문의 대상 장면과 겹치는 문항도 있습니다	**더 엄격한 채점**: 질문을 보지 않는 Matcher 또는 의미 일치 직접 판정

부록. 재현 경로

내용	경로
최종 구성, 비교 대상	`configs/nep_agent.yaml`, `configs/plain_qwen.yaml`
벤치마크 실행	`scripts/run_benchmark.py` (결과는 `results/quantitative/runs/`에 저장됨)
도구 1종 실행 (표 2)	`configs/ablation/tools_only_*.yaml`
표 생성	`scripts/main_table.py`(표 1), `scripts/tool_ablation.py`(표 2)
학습 설정	`src/train/configs/nep_agent_tool_evidence.yaml`
테스트 케이스, 실패 사례	`results/qualitative/`, `results/failure_cases/`

참고 문헌

- [1] S. Bai et al., "Qwen3-VL Technical Report", arXiv:2511.21631.
- [2] Q. Chen et al., "FutureOmni: Evaluating Future Forecasting from Omni-Modal Context for Multimodal LLMs", arXiv:2601.13836.
- [3] H. Wang et al., "Fostering Video Reasoning via Next-Event Prediction", arXiv:2505.22457.
- [4] Q. Su et al., "Video-CoE: Reinforcing Video Event Prediction via Chain of Events", arXiv:2603.14935.
- [5] Q. Chen et al., "VepAgent: Bridging Causal-Transition via Tool-Augmented Reinforcement Learning for Video Event Prediction", arXiv:2610.06293.
- [6] Y. Lee et al., "ViKey: Enhancing Temporal Understanding in Videos via Visual Prompting", arXiv:2603.23186.
- [7] A. Radford et al., "Robust Speech Recognition via Large-Scale Weak Supervision", arXiv:2212.04356.
- [8] S. Liu et al., "Grounding DINO: Marrying DINO with Grounded Pre-Training for Open-Set Object Detection", arXiv:2303.05499.